

GME论文中结果

		ML-1M	
Pred. model	Emb. model	AUC	Loss
DNN	RndEmb	0.7107	0.6491
	MetaEmb	0.7144	0.6439
	NgbEmb	0.7131	0.6442
	GME-P	0.7146	0.6437
	GME-G	0.7217	0.6389
	GME-A	0.7232	0.6368

加入变分自编码器模块 0.721442

0.633415

User Diverse Preference Modeling by Multimodal Attentive Metric Learning

ABSTRACT

大多数现有的推荐系统用特征向量表示用户的偏好，当预测该用户对不同项目的偏好时，假设特征向量是固定的。然而，**同一个向量无法准确捕捉用户对所有项目的不同偏好**，尤其是在考虑各种项目的不同特征时。为了解决这一问题，在本文中，我们提出了一种新的多模态注意度量学习

(MAML) 方法，**以建模用户对各种项目的不同偏好**。特别是，对于每个用户-项目对，我们提出了一个注意力神经网络，该网络利用项目的多模态特征来估计用户对该项目不同方面的特别关注。然后将获得的注意力集成到基于度量的学习方法中，以预测用户对该项目的偏好。度量学习的优点是它可以自然地克服基于矩阵分解（MF）的推荐模型所采用的点积相似性问题，但不满足三角形不等式性质。此外，值得一提的是，注意力机制不仅有助于对用户在不同项目的不同偏好进行建模，而且还克服了协作度量学习带来的几何限制问题。在大规模真实世界数据集上的大量实验表明，我们的模型可以大大优于最先进的基线，证明了建模用户对推荐的不同偏好的潜力。

3 OUR PROPOSED MODEL

3.1 Notations and Background

Notations.

在描述我们的模型之前，我们首先要定义一些基本符号。设 U 为用户集， I 为项目集， R 为用户-项目交互矩阵。 $r_{u,i} \in R$ 表示用户 $u \in U$ 和项目 $i \in I$ 之间的交互。交互可以是隐式的，也可以是显式的。对于隐式反馈，如果 u 和 i 之间存在相互作用，则 $r_{u,i}=1$ ；否则， $r_{u,i}=0$ 。对于显式反馈， $r_{u,i}$ 通常是 u 对 i 的评级。设 R 是值为非零的用户项 (u, i) 对的集合， R_u 是已被 u 交互的项的集合。 $p_u \in R^f$ 和 $q_i \in R^f$ 分别表示 u 和 i 的潜在特征向量。推荐系统的核心是学习用户和项目（即 p_u 和 q_i ）的潜在特征向量。当向用户 u 推荐项目时，对于每个项目 $j \notin R_u$ ，其推荐分数 $\hat{R}_{u,j}$ 基于 p_u 和 q_j 计算。

Background.

矩阵分解（MF）将用户和项目映射到共享的潜在特征空间中，并通过用户和项目向量之间的点积来估计看不见的交互，即， $\hat{r}_{u,i} = p_u^T q_i$ 。对于所有 $u \in U$ 和 $i \in I$ ， p_u 和 q_i 都是通过最小化 $r_{u,i}$ 和 $\hat{r}_{u,i}$ 之间的预测误差来求得的，即： $\sum_{u,i \in R} \|\hat{r}_{u,i} - r_{u,i}\|$ 。由于其简单性和优越的性能，矩阵分解已成为过去十年中最流行的协作过滤方法。原始MF模型被设计用于评级预测，并被扩展为加权正则化矩阵分解（WRMF）用于隐式反馈预测。由于推荐系统的目标是为目标用户提供最有可能被用户偏好的前几项的排名列表，因此推荐是一个排名问题，而不是评分问题。有鉴于此，MF开始对不同项目之间的相对偏好进行建模，并广泛采用成对学习方法来实现目标。

在成对学习中，通过对任意两个满足 $(u, i) \in R$ 且 $(u, k) \notin R$ 的对设置 $\hat{r}_{u,i} > \hat{r}_{u,k}$ 来学习用户向量和项目向量。一个典型的例子是贝叶斯个性化排序(BPR)。它是一种基于MF的优化方法，其中 $\hat{r}_{u,i} = p_u^T q_i$ ， $\hat{r}_{u,k} = p_u^T q_k$ 因此采用 $p_u^T q_i > p_u^T q_k$ (s.t. $(u, i) \in R$ 和 $(u, k) \notin R$)进行优化

尽管MF取得了成功，但它不是一种基于度量的学习方法，因为采用的点积相似度不满足三角形不等式性质，这对于建模细粒度用户偏好至关重要，如[20, 53]所示。从度量学习的角度来看，由于用户和项目被表示为共享空间中的潜在向量，因此可以基于其向量之间的欧几里得距离来估计用户和项目之间的相似性：

$$d(u, i) = \|p_u - q_i\|. \quad (1)$$

考虑到成对学习，很自然地得出 $d(u, i) < d(u, k)$ $(u, i) \in R$ 和 $(u, k) \notin R$ ，其中 i 表示 u 喜欢的项目， k 表示 u 不喜欢的项目。协作度量学习

(CML) [20]就是基于这个简单的思想设计的。由于该方法是一种基于度量的学习方法，它自然地避免了点积的限制，并实现了比MF模型更好的性

能。因此，在这项工作中，我们还基于这种方法而不是MF推导了我们的用户多样性偏好建模方法。

3.2 Multimodal Attentive Metric Learning

3.2.1 Overview.

在上述方法中，它们都使用固定向量 p_u 来表示用户 u 在特征空间中的偏好。在那些将用户和项目映射到用于相似性估计的联合潜在空间中的模型中，它们都假设空间中的每个维度代表项目的特征类型或方面。这些维度/方面有望很好地描述和区分不同用户的偏好。基于这种理解，我们认为使用相同的向量 p_u 来预测 u 对所有项目的偏好可能不是最佳的，因为在实际场景中，用户对不同项目的偏好是不同的。例如，喜欢一家餐厅的味道和价格的用户可能会更关注另一家餐厅，因为这两家餐厅的服务目的不同。当预测用户 u 对项目 i 的偏好时， u 最关注的项目 i 的那些方面应该主导 u 对项目 i 的偏好。

有鉴于此，我们提出了一种多模态注意力度量学习 (MAML) 模型。对于每个用户项 (u, i) 对，我们的模型计算权重向量 $a_{u, i} \in R^f$ 表示 i 的方面对 u 的重要性。此外，利用项目的边信息来估计权重向量，因为边信息传达了项目的丰富特征，尤其是文本评论和项目图像，它们被公认为在不同方面提供项目的显著和互补特征[9, 54]。我们采用注意力机制的最新进展来估计注意力向量。通过注意力（权重）向量，我们的模型中用户 u 和项目 i 之间的欧几里得距离变为：

$$d(u, i) = \|a_{u, i} \odot p_u - a_{u, i} \odot q_i\|, \quad (2)$$

\odot 表示向量之间的element-wise 乘积。

值得一提的是，利用注意力向量，我们的模型不仅可以准确捕捉用户对不同项目的不同偏好，还可以解决CML中的几何限制问题。从等式1可以发现，CML试图将一个用户和所有交互的项目放入潜在空间中的同一点，然而，每个项目又有许多交互的用户。因此，几何上不可能实现这一目标。在我们的模型中，作为 $a_{u, i}$ 对于每个用户-项目对都是唯一的，它作为一个转换向量，将目标用户和项目转换为一个新的距离计算空间。因此，我们的方法可以自然地避免CML中的几何限制问题。我们提出的模态MAML的概述如图1所示。

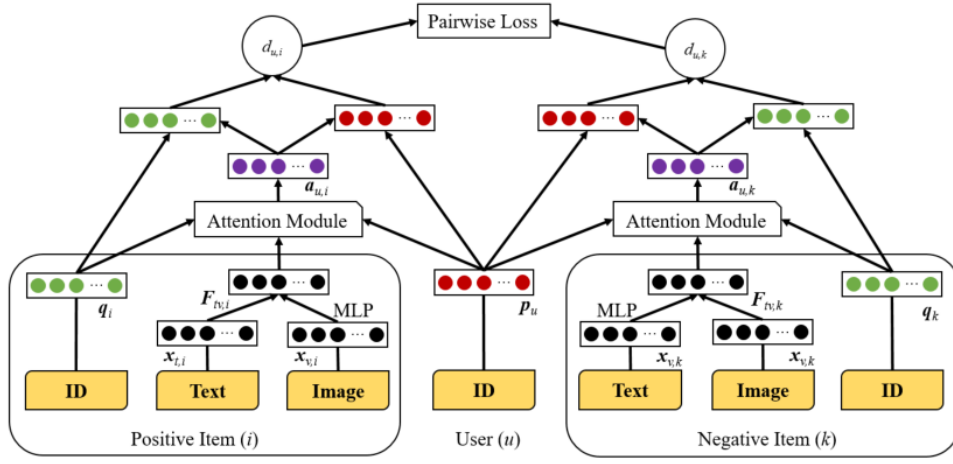


Figure 1: Overview of our MAML model.

我们采用成对学习进行优化，损失函数定义为：

$$L_m(d) = \sum_{(u,i) \in R} \sum_{(u,k) \notin R} \omega_{ui} [m + d(u,i)^2 - d(u,k)^2]_+, \quad (3)$$

其中 i 是 u 喜欢的项目， k 是 u 不喜欢的项目； $[z]_+ = \max(z, 0)$ 表示标准 hinge loss。 ω_{ui} 是排名损失权重（如第3.2.3节所述）， $m > 0$ 是 safety margin size。根据等式2计算 $d(u, i)$ 和 $d(u, k)$ 。接下来，我们介绍如何计算每个用户项对的关注向量 $a_{u, i}$ 。

3.2.2 Attention Mechanism.

在本节中，我们介绍了MAML中的注意力机制，用于捕获用户 u 对项目 i 的特定注意力 $a_{u, i}$ 。由于文本评论和图像包含关于用户偏好和项目特征的丰富信息，因此它们用于捕获 u 对 i 各个方面的注意力。使用两层神经网络计算注意力向量：

$$\mathbf{e}_{u,i} = \text{Tanh}(\mathbf{W}_1[\mathbf{p}_u; \mathbf{q}_i; \mathbf{F}_{tv,i}] + \mathbf{b}_1), \quad (4)$$

$$\hat{\mathbf{a}}_{u,i} = \mathbf{v}^T \text{ReLU}(\mathbf{W}_2 \mathbf{e}_{u,i} + \mathbf{b}_2), \quad (5)$$

其中 \mathbf{W}_1 、 \mathbf{W}_2 和 \mathbf{b}_1 、 \mathbf{b}_2 分别是两层的权重矩阵和偏置向量。 \mathbf{v} 是将隐藏层投影为输出注意权重向量的向量。 $\mathbf{F}_{tv, i}$ 是项目特征向量，它是 i 的文本特征和图像特征（稍后描述）的融合。 $[\mathbf{p}_u; \mathbf{q}_i; \mathbf{F}_{tv, i}]$ 表示 \mathbf{p}_u 、 \mathbf{q}_i 和 $\mathbf{F}_{tv, i}$ 的串联。 Tanh 和 ReLU 分别用作第一层和第二层的激活函数。

遵循神经注意力网络的标准程序，接下来的步骤是使用 softmax 函数对 $a_{u, i}$ 进行归一化，softmax 归一化后，权重将非常小。例如，当维度 f 为 100 时，权重的平均值仅为 0.01。请注意， \mathbf{p}_u 和 \mathbf{q}_i 的每个维度之间的距离已经很小了。对于如此小的权重 $a_{u, i, l}$ ，距离 $d_{u, i, l}$ 变得更小。当所有维度的距

离都很小时，不同维度（方面）之间的差异可以忽略不计。这将削弱我们模型的识别能力，导致性能下降。为了缓解这个问题，我们建议将归一化权重放大一个因子 α 。在我们的模型中，最终注意力权重向量计算如下：

$$a_{u,i,l} = \alpha \cdot \frac{\exp(\hat{a}_{u,i,l})}{\sum_{l=1}^f \hat{a}_{u,i,l}}. \quad (6)$$

在实验中，我们将 α 设为权重向量的维数，即 $\alpha=f$ ，结果证明其效果良好（参见第4.3节）。接下来，我们将介绍如何获得融合项目特征向量 $F_{tv,i}$ 。

Item Features.

对于每个项目，其文本和视觉特征都是从其相关评论和图像中提取的。文本特征 $F_{t,i}$ 由PV-DM模型提取。视觉特征 $F_{v,i}$ 由Caffe参考模型提取，该模型由5个卷积层和3个完全连接层组成。该模型在120万张ImageNet (ILSVRC2010) 图像上进行了预训练。在这项工作中，我们采用第二个完全连接层的输出，得到4096-D特征向量作为每个项目的视觉特征。

在提取项目的文本和视觉特征后，我们融合它们以更好地表示项目的特征。已经提出了许多多模态特征融合方法，我们采用了一种广泛使用的策略，首先连接文本和视觉特征，然后将它们输入多层神经网络。具体而言，

$$\begin{aligned} z_1 &= \sigma(W_1[F_{t,i}; F_{v,i}] + b_1), \\ z_2 &= \sigma(W_2 z_1 + b_2), \\ &\dots\dots, \\ z_L &= \sigma(W_L z_{L-1} + b_L), \end{aligned} \quad (7)$$

其中 W_l 和 b_l 分别表示第 l 层的权重矩阵和偏置向量。 $\sigma(\cdot)$ 是激活函数，采用ReLU是因为其生物学上合理且不饱和的性质。最后一层的输出是融合特征，即 $F_{tv,i}=z_L$ 。注意到，我们在本文中的重点是利用物品的多模态特征来捕捉用户对不同物品不同方面的不同关注。为了简化起见，采用了上述提取和融合方法，在这种情况下也可以采用其他先进的特征提取和融合方式。

3.2.3 Ranking loss weight.

我们采用加权近似秩对 (WARP) 损失[48]来计算 $\omega_{u,i}$ 。该方案对秩较低的正项的惩罚要比排名靠前的负项严重得多，并产生了先前工作中最先进的结果。给定度量 d ，让 $\text{rank}_d(u, i)$ 表示 i 在 u 的推荐排名列表中的位置， $\omega_{u,i}$ 计算为，

$$\omega_{u,i} = \log(\text{rank}_d(u, i) + 1). \quad (8)$$

在WARP中， $\text{rank}_d(u, i)$ 是通过连续采样程序来估计的，该程序重复采样负项目以找到冒名顶替者[48]。对于每个用户项目对 (u, i) ，让 J 表示项目的总数， M 表示 N 个样本中的冒名顶替者的数量。 $\text{rank}_d(u, i)$ 近似为 $\lfloor (J \times M) / N \rfloor$ 。在我们的实现中，我们遵循[20]中描述的过程来估计 $\text{rank}_d(u, i)$ 。

3.2.4 Regularization.

由于文本评论和项目图像代表项目的特征，我们希望具有相似文本和视觉特征的项目在潜在特征向量中更接近。为了实现该目标，我们定义了以下L2损失函数，

$$L_f(q_*) = \sum_i \|F_{tv,i} - q_i\|. \quad (9)$$

当 q_i 偏离提取的特征 $F_{tv,i}$ 时，该函数惩罚项目 i 的特征向量 q_i

为了防止特征空间中每个维度的冗余，我们随后使用另一种正则化技术，协方差正则化来减少深度神经网络中激活之间的相关性。该技术也可用于我们的模型中，以使特征空间中的维度去相关，从而最大限度地利用给定空间。设 y_n 表示对象的潜在向量，该对象可以是用户或项目；矩阵 C 中所有维度 i 和 j 对之间的协方差定义为：

$$C_{i,j} = \frac{1}{N} \sum_n (y_i^n - \mu_i) (y_j^n - \mu_j), \quad (10)$$

其中 $\mu_i = \frac{1}{N} \sum_n y_i^n$ 。我们定义损失 L_c 来正则化协方差：

$$L_c = \frac{1}{N} \left(\|C\|_f - \|\text{diag}(C)\|_2^2 \right), \quad (11)$$

哪里 $\|\cdot\|_f$ 是Frobenius范数

最后，类似于先前基于度量的协作过滤方法，我们还将所有用户和项目向量绑定在欧几里得单位球内，即。 $\|p^*\|^2 \leq 1$ 和 $\|q^*\|^2 \leq 1$ ，用于正则化和防止过度拟合。

3.3 Optimization

考虑到所有正则化项，我们的MAML的最终目标函数是，

$$\begin{aligned} \min_{\theta, p^*, q^*} \quad & L_m + \lambda_f L_f + \lambda_c L_c \\ \text{s.t.} \quad & \|p^*\|^2 \leq 1 \text{ and } \|q^*\|^2 \leq 1, \end{aligned} \tag{12}$$

其中 λ_f 和 λ_c 是控制每个损失项权重的超参数。优化是非常标准的，并且采用了随机梯度下降（SGD）算法。在实现中，采用Adam优化器来调整学习速率。

Contrastive Learning for Cold-Start Recommendation

<https://dl.acm.org/doi/pdf/10.1145/3474085.3475665>

ABSTRACT

推荐纯冷启动项目是推荐系统中长期存在的基本挑战。在没有任何关于冷启动项目的历史交互的情况下，协同过滤（CF）方案无法利用协同信号来推断用户对这些项目的偏好。为了解决这个问题，已经进行了广泛的研究，将项目的附加信息（例如，内容特征）纳入CF方案。具体而言，他们使用现代神经网络技术（例如，缺失、一致性约束）来发现和利用**内容特征**和**协同表示**的联合效应。然而，我们认为，这些工作较少探索内容特征和协同表示之间的相互依赖性，缺乏足够的理论支持，从而导致冷启动推荐的性能不理想。

在这项工作中，我们从信息论的角度重新定义了冷启动项目表示学习。它旨在**最大化项目内容和协同信号之间的相互依赖性**。具体地说，表示学习理论上是由两个术语的集成所限定的下限：用户和项目的协同嵌入之间的互信息，以及项目的协同嵌入和特征表示之间的互信息。为了模拟这样的学习过程，我们设计了一个基于对比学习的新目标函数，并开发了一个简单而高效的基于对比学习冷启动推荐框架（CLCRec）。特别是，CLCRec由三个组件组成：对比对结构、对比嵌入和对比优化模块。它允许我们在暖启动和冷启动项目的内容表示中保留协同信号。通过对四个可公开访问的

数据集的广泛实验，我们观察到CLCRec在热启动和冷启动场景中都比现有技术方法有了显著的改进。

互信息描述了不确定性方面的关系。两个量之间的互信息 (MI) 是衡量一个量的知识减少另一个量的不确定性的程度。

1 INTRODUCTION

协同过滤 (CF) 在个性化推荐方面取得了显著的成功。从历史交互 (例如点击、评分、观点) 中学习用户和项目的质量表示是现代CF模型的核心。我们将编码协同信号的表示表示为协同嵌入，例如MF中的ID嵌入、SVD++中的交互历史嵌入以及LightGCN中的交互图嵌入。这种协同嵌入反映了用户的行为相似性，从而有效地推断出用户对项目的偏好。显然，历史用户-项目交互对于建立高质量的协同嵌入至关重要。然而，有大量新出现的项目，这些项目从未出现过，这对冷启动推荐提出了严峻的挑战。这是因为无法用交互来学习这些冷启动项目的协同嵌入。

为了解决这个问题，一个常见的解决方案是将项目内容 (例如，图像、视频、属性) 合并到CF方案中。内容特征应该与协同表示合作，形成联盟，并提供更好的预测。CF模型中存储的这种联合效应允许我们将协同知识转移到冷启动项目中。在这一研究领域，进行了广泛的研究，大致可以分为两类，**基于鲁棒性的**[7, 31, 36] 和**基于约束的**[3, 22, 30, 47]。尽管取得了成功，但每种方法都有一些固有的局限性：

- 从鲁棒性学习的角度来看，**基于鲁棒性的方法将冷启动项目定义为缺少交互作用的热项目的损坏形式**。从技术上讲，他们通过随机破坏暖物品的协同嵌入[7, 36]或手工制作新物品[21, 35]来增强训练数据，从而增强对未看到物品的泛化能力。然而，没有设计任何功能来明确考虑项目内容和协同嵌入之间的关系，因此很难为冷启动项目提炼有用的协同信号。

- 基于约束的方法[2, 3, 47]**通过应用约束损失来明确建模项目内容和协同嵌入之间的关系**。具体而言，对于一个项目，其内容作为特征表示进行传输；此后。约束损失，(如L2正则化器) 强制特征表示和协同嵌入之间的维度相似性。尽管如此，仍有两个局限性：(1) 这种维正则化仅仅保持了这两种表示之间的一致性，这可能会丢弃异构和独特的信息；(2) 它缺乏足够的理论支持来确保在特征表示中保留了什么以及多少关于协同嵌入的信息。

简言之，尽管受到神经网络技术的进步 (例如，Dropout[33]和约束[47]) 的推动，这些现有方法不足以促进冷启动项目推荐。

在这项工作中，我们旨在探索冷启动表征学习的深入和理论方面。具体而言，**我们将特征表示的学习重新定义为在观察到的交互和学习到的协同嵌入下优化其最大后验估计**。这种优化允许我们从协同嵌入中提取有意义的信息，并将它们编码为暖启动和冷启动项目的特征表示。更正式地说，后验估计量的下限是两个项的积分：（1）**用户和项目协同嵌入之间的互信息（缩写为UI）**和（2）**特征表示和协同嵌入之间互信息（缩写为R-E）**。为了最大限度地利用互信息，我们提出了一种基于对比学习[4, 5, 26, 34]的新目标函数。

为了实现我们提出的目标功能，我们进一步开发了一个通用框架，名为基于对比学习的冷启动建议（CLCRec）。从技术上讲，它由三个关键部分组成。（1）我们首先进行对比对结构。对于U-I损失，我们将观察到的历史交互视为积极的用户-项目对，而将未观察到的交互视为消极的用户-项目对。同时，对于R-E损失，我们采用了项目的自辨别任务，其中一个项目与自身配对，其他项目分别指正项目和负项目对。（2）在建立了U-I和R-E对比对之后，我们在其上构建了对比嵌入网络（CEN）。U-I CEN将为用户项目对生成协同嵌入，该嵌入可以构建在任何CF编码器（如MF和LightGCN）上。R-E CEN包含一个可训练的编码器，用于根据项目的内容特征学习项目的特征表示。（3）然后，我们根据设计的目标函数进行对比优化。使用预定义的密度比函数，我们对构建的U-I和R-E对比对进行评分，然后进行对比训练，即从多个负样本对中识别正样本对。因此，训练两个CEN来指导特征表示和协同嵌入的学习，并鼓励它们之间的信息传递。在测试阶段，对于一个冷启动项目，我们能够生成高质量的特征表示，这些特征表示能够从观察到的交互中记忆信息信号，并预测用户采用它的可能性。通过对四个真实世界数据集的广泛实验，我们证明CLCRec在暖启动和冷启动场景中都比最先进的方法取得了显著的改进。我们总结了以下贡献：

- 我们将冷启动表示学习重新定义为最大化U-I和R-E互信息之和。
- 为了实现互信息最大化，我们设计了一个基于对比学习的目标函数，并相应地提出了一个通用框架CLCRec。
- 我们对四个公共数据集进行了广泛的实验，以证明CLCRec的优越性。

2 METHODOLOGY

在这项工作中，我们重点推荐没有任何互动的完整冷启动项目，这更具挑战性和前景。在描述所提出方法的细节之前，我们重新制订了冷启动问题，并相应地导出了目标函数。

2.1 Problem Formalization

Learning of Collaborative Embeddings.

设 $O=\{o_{u,i}\}$ 是用户-项目交互的集合，它包括 N 个用户的集合， $U=\{u\}$ ，和 M 个项目的集合， $I=\{i\}$ 。假设具有相似行为的用户更喜欢相似的项目，现代协同过滤（CF）方法从历史交互中学习用户和项目的协同嵌入。在不失一般性的情况下，我们描述一个用户 u （一个项目 i ）使用协同嵌入 $z_u \in R^d$ （ $z_i \in R^d$ ）， d 是嵌入大小。优化协同嵌入是在给定观察到的相互作用的情况下最大化后验估计：

$$Z^* = \arg \max_Z p(Z|O), \quad (1)$$

其中 $Z=[z_{i1}, \dots, z_{iN}, z_{u1}, \dots, z_{uM}]$ 收集所有用户和项目的协同嵌入； $p(Z|O)$ 是将尽可能多的关于 O 的信息编码成 Z 。然而，对于冷启动项目 $I^c = \{i^c\}$ 如果没有任何历史交互，CF不可能优化其协同嵌入，因此无法准确预测用户偏好。

Learning of Feature Representations.

为了缓解这个问题，已经进行了广泛的研究，以利用物品的丰富侧面信息，特别是内容特征（例如，视频帧、音乐配乐和产品描述）。通常，在内容特征向量 x_i 的基础上构建特征编码器 f_θ ，以生成项目 i 的特征表示 f_i 。这里我们将特征表示和内容特征的集合建立为 $F=[f_{i1}, \dots, f_{iN}]$, $X=[x_{i1}, \dots, x_{iN}]$ ，分别地请注意，可学习的 F 因此不同于预训练特征提取器学习的 X [25, 38]。先前的工作要么单独处理特征表示和协同嵌入[7, 31, 36]，要么应用正则化项来鼓励它们的维度相似性[2, 22, 30]。与这些方法不同，我们通过**鼓励特征表示**（1）对来自协同嵌入的协同信号进行编码，以及（2）保持与以前交互过的用户的亲密关系来优化特征编码器。为此，我们将项目表示学习重新定义为最大化后验估计，给定嵌入和交互：

$$\theta^* = \arg \max_{\theta} p(\theta|Z, O, X). \quad (2)$$

已获得优化特征编码器 θ^* ，我们为冷启动项目生成特征表示，该表示通过来自warm项目的协同知识得到增强。最后，我们可以通过测量冷启动项目和用户表示的相似性来推断他们之间的交互概率。

2.2 Objective Function

由于预先存在的内容特征 \mathbf{x} 通常独立于协同嵌入 \mathbf{z} ，因此我们可以采用贝叶斯规则并将等式 (2) 改写如下：

$$p(\theta|\mathbf{Z}, \mathbf{O}, \mathbf{X}) \propto p(\mathbf{Z}, \mathbf{O}|\mathbf{F}) \cdot p(\theta). \quad (3)$$

根据先前的研究[29]，我们假设所有项目（和用户）彼此独立。因此，我们可以进一步获得以下概率，分别将特征表示与协同嵌入和交互相关联：

$$\begin{aligned} p(\mathbf{Z}, \mathbf{O}|\mathbf{F}) \cdot p(\theta) &\propto \sum_{i \in \mathcal{I}} \ln p(\mathbf{z}_i, \mathbf{z}_{u_1}, \mathbf{z}_{u_2}, \dots, \mathbf{z}_{u_N} | \mathbf{f}_i) + \ln p(\theta) \\ &= \sum_{i \in \mathcal{I}} \ln p(\mathbf{z}_i, \mathbf{f}_i) + \sum_{(u,i) \in \mathcal{O}} \ln p(\mathbf{z}_u | \mathbf{z}_i, \mathbf{f}_i) + C \sum_{u \in \mathcal{U}} \ln p(\mathbf{z}_u) + \ln p(\theta). \end{aligned}$$

在这里 C 是从条件概率之和导出的常数项： $\sum_{(u,i) \notin \mathcal{O}} \ln p(\mathbf{z}_u | \mathbf{z}_i, \mathbf{f}_i)$ 。它捕捉到一种直觉，即一个项目独立于以前没有与之交互的用户，而交互的存在表明了他们的独立性。

在这个方程中，第一项侧重于 \mathbf{z}_i 和 \mathbf{f}_i 之间的相关性，从而鼓励 \mathbf{z}_i 嵌入 \mathbf{f}_i 的信息。因此，从三种表示之间的复杂关系出发，我们可以解除第二项 $\sum_{(u,i) \in \mathcal{O}} \ln p(\mathbf{z}_u | \mathbf{z}_i, \mathbf{f}_i)$ 。具体而言，在观察项目嵌入之后，它与用户嵌入的后验概率成比例：

$$\begin{aligned} &\sum_{i \in \mathcal{I}} \ln p(\mathbf{z}_i, \mathbf{f}_i) + \sum_{(u,i) \in \mathcal{O}} \ln p(\mathbf{z}_u | \mathbf{z}_i, \mathbf{f}_i) + C \sum_{u \in \mathcal{U}} \ln p(\mathbf{z}_u) + \ln p(\theta) \\ &\propto \sum_{i \in \mathcal{I}} \ln p(\mathbf{z}_i, \mathbf{f}_i) + \sum_{(u,i) \in \mathcal{O}} \ln p(\mathbf{z}_u | \mathbf{z}_i) + C \sum_{u \in \mathcal{U}} \ln p(\mathbf{z}_u) + \ln p(\theta). \end{aligned}$$

随后，我们证明了该后验概率的下界是两个分量的总和：（1）用户和项目的协同嵌入之间的U-I互信息，以及（2）协同嵌入和项目的特征表示之间的R-E互信息：

$$\begin{aligned}
& \sum_{i \in I} \ln p(z_i, f_i) + \sum_{(u,i) \in O} \ln p(z_u | z_i) + C \sum_{u \in \mathcal{U}} \ln p(z_u) + \ln p(\theta) \\
& \geq \underbrace{\sum_{i \in I} p(f_i, z_i) \ln \frac{p(z_i, f_i)}{p(z_i)p(f_i)}}_{MI(F, Z_I)} + \underbrace{\sum_{(i,j) \in O} p(z_u, z_i) \ln \frac{p(z_u | z_i)}{p(z_u)}}_{MI(Z_I, Z_U)} \\
& + \underbrace{\sum_{i \in I} \ln p(f_i) + \sum_{i \in I} \ln p(z_i) + (C+1) \sum_{u \in \mathcal{U}} \ln p(z_u) + \ln p(\theta)}_{\ln p(\Theta)}
\end{aligned}$$

$MI(\cdot, \cdot)$ 表示两个表示之间的互信息。此外，我们使用 Θ 来表示其先验概率可能遵循高斯分布的所有参数。因此，我们将目标从最大后验估计量转换为互信息最大化。

为了最大化互信息，我们采用了对比学习技术，该技术通过识别正对和负对来建模变量对的相互依赖性。具体而言，根据先前的工作[26]，我们定义了两个密度比函数：

$$h(z_i, f_i) \propto \frac{p(f_i | z_i)}{p(f_i)}, \quad g(z_u, z_i) \propto \frac{p(z_u | z_i)}{p(z_u)}. \quad (4)$$

这些功能（即， $h(\cdot, \cdot)$ 和 $g(\cdot, \cdot)$ ）可用于测量两个变量之间的相关性。因此，基于对比学习的目标函数可以表述为：

$$\begin{aligned}
\mathcal{L} &= \lambda \mathcal{L}_{RE} + (1 - \lambda) \mathcal{L}_{UI} + \eta \|\Theta\|_2^2 \\
&= -\lambda \mathbb{E}_{i \in I} \left[\ln \frac{h(z_i, f_i)}{h(z_i, f_i) + \sum_{j \in I/\{i\}} h(z_i, f_j)} \right] \\
&\quad - (1 - \lambda) \mathbb{E}_{(u,i) \in O} \left[\ln \frac{g(z_u, z_i)}{g(z_u, z_i) + \sum_{(u,j) \notin O} g(z_u, z_j)} \right] + \eta \|\Theta\|_2^2.
\end{aligned} \quad (5)$$

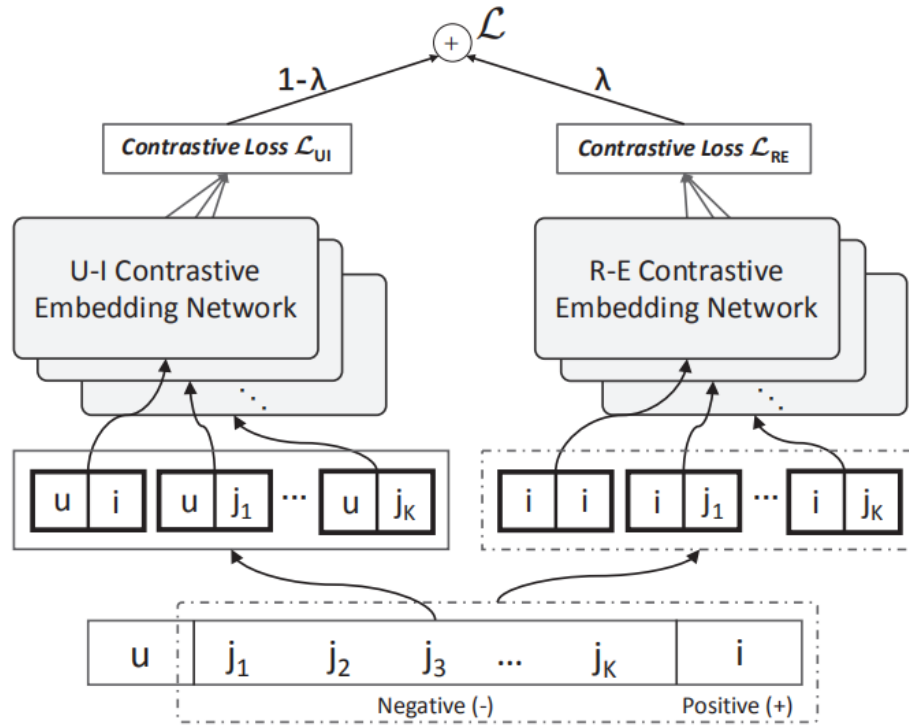
我们使用 LRE 和 LUI 以分别表示用于最大化 R-E 和 U-I 互信息的对比度损失。作为 LUI 与个性化排名（BPR）损失具有相同的优化目标[29]，我们可以在没有任何其他损失函数的情况下以端到端的方式优化推荐模型，并设置一个超参数 λ 以平衡协同和特征表示学习。

2.3 CLCRec

根据目标函数，我们开发了一个通用框架，即基于对比学习的冷启动建议（CLCRec），如图1（a）所示。该框架由三个部分组成：对比对组织、对比嵌入网络 and 对比优化。在下文中，我们详细阐述了每个组件的细节。

2.3.1 Contrastive Pair Organization.

对比学习的核心是从由不同样本配对的否定实例中识别由语义相似实例构建的肯定对。因此，在这项工作中，将用户和项目组织为U-I和R-E对比对至关重要。



(a) Illustration of framework.

U-I Contrastive Pair

我们将历史交互中观察到的用户项对视为正面样本，如如图1（a）所示(u, i)。同时，我们随机抽样 K 个尚未由 u 购买的项目（例如(j_1, j_2, \dots, j_K)), , 并将用户配对以建立负样本对，如图1（a）所示。正负U-I对在形式上可以定义为，

$$\{(u, i), (u, j_1), (u, j_2), \dots, (u, j_K)\}. \quad (6)$$

与负样本配对相比，正样本配对包含相似的协同信号。因此，这种比较有助于发现由交互传递的协同信号。

R-E Contrastive Pair.

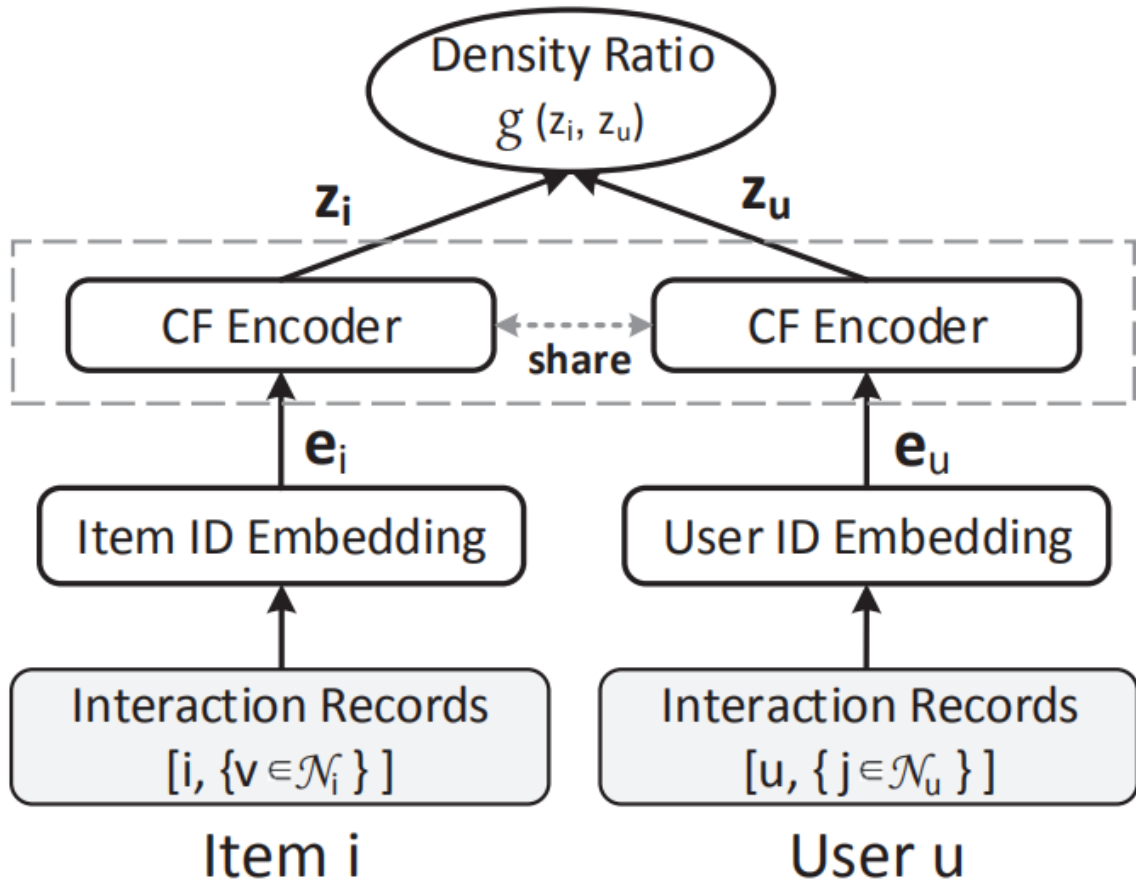
与U-I对不同，R-E对采用自鉴别任务，以最大化项目的两种不同表示的互信息。为了构建这些对，以图1 (a) 中的*i*为例，我们将其设置为锚定项，并将其自身作为正对连接锚定，这揭示了同一项的两个表示之间的语义相似性。相比之下，锚与其他项目组织的负样本对在语义上是不同的。如图1 (a) 所示，我们将项目配对在一起以获得R-E对：

$$\{(i, i), (i, j_1), (i, j_2), \dots, (i, j_K)\}, \quad (7)$$

其中(*i*, *i*) 是正对，其他是负对。

对于对比对，我们设计U-I和R-E对比嵌入网络（CEN）来表示用户和项目，并使用预定义的密度比函数计算每对的相关性。

U-I Contrastive Embedding Network.



(b) Illustration of U-I CEN.

为了从用户-项目交互中建模协同信号，我们首先获取它们的id嵌入（例如 e_u 和 e_i ）从由参数矩阵定义的查找表：

$$\mathbf{E} = [\mathbf{e}_{i_1}, \dots, \mathbf{e}_{i_N}, \mathbf{e}_{u_1}, \dots, \mathbf{e}_{u_M}]. \quad (8)$$

然后，使用共享CF编码器来学习用户和项目的协同嵌入，如图1（b）所示。它可以通过各种模型来实现，例如基于MF的[20, 29]、基于神经网络的[13]和基于图神经网络的[12, 37, 39]模型。在这项工作中，我们提供了两个简单但高效的实现，CENMF 和CENGCN，其分别基于MF[20]和LightGCN[12]。为了简洁起见，我们忽略了它们的细节，将它们表示为，

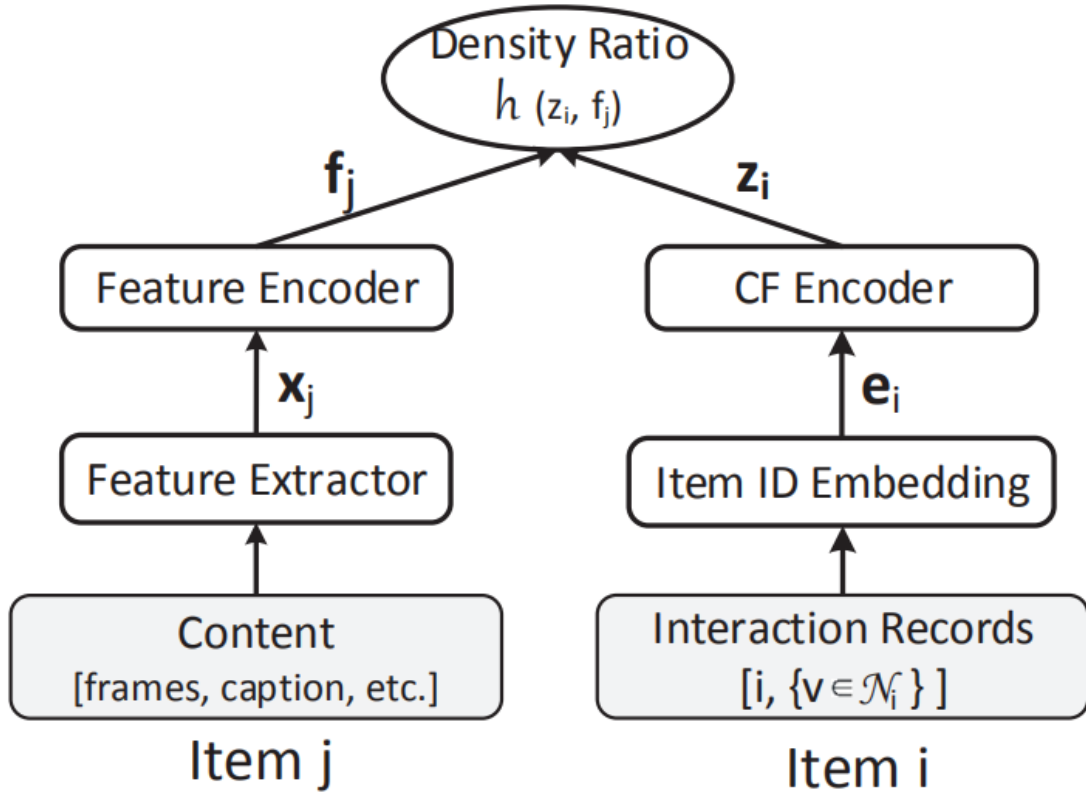
$$\begin{cases} \mathbf{z}_i = \mathcal{E}(\mathbf{e}_i, \{\mathbf{e}_v | v \in \mathcal{N}_i\}) \\ \mathbf{z}_u = \mathcal{E}(\mathbf{e}_u, \{\mathbf{e}_j | j \in \mathcal{N}_u\}), \end{cases} \quad (9)$$

其中， \mathcal{E} 是以id嵌入为输入的CF编码器； \mathcal{N}_i 是与项目 i 交互的用户集，而 \mathcal{N}_u 表示用户 u 已购买的项目集。已获得用户项对（即 $\mathbf{z}_i, \mathbf{z}_u$ ），我们定义以下函数来测量它们的相关性：

$$g(\mathbf{z}_i, \mathbf{z}_u) = \exp(\mathbf{z}_i^\top \mathbf{z}_u / \tau), \quad (10)$$

其中 τ 是温度参数[4]。在这里，我们使用内积来接近相关性，在未来的工作中留下对其他非负函数的探索[26]。

R-E Contrastive Embedding Network.



(c) Illustration of R-E CEN.

该网络用于对项目的两个视图（协同信号和内容信息）之间的相关性进行评分。如图1（c）所示，可以将其视为两条并行管道，分别对项目的特征表示和协同嵌入进行建模。协同嵌入的正确方法与U-I网络中的相应操作相同

为了表示内容信息，我们使用了特征提取器，它可以是预训练的深度学习模型，然后是特征编码器。更具体地说，对于项目 j 在R-E对比对中，我们提取其特征向量，表示为 \mathbf{x}_j ，根据内容信息。然后，我们将特征编码器设计为具有一个隐藏层的多层感知器（MLP）

$$\mathbf{f}_j = \mathbf{W}^{(2)} \phi(\mathbf{W}^{(1)} \mathbf{x}_j + \mathbf{b}^{(1)}) + \mathbf{b}^{(2)}, \quad (11)$$

其中 $\mathbf{W}(\cdot)$ 和 $\mathbf{b}(\cdot)$ 分别表示编码器的可训练矩阵和偏置向量。此外， \mathbf{f}_j 是项目 j 的所需特征表示，其目的在于提取内容特征并最大限度地保留与协同信号相关联的信息。在推理阶段，由这样的特征表示支持，我们可以测量用户和冷启动项目之间的亲和力。

在获得两条管道的输出（即项目的协同嵌入和特征表示）后，我们使用以下函数对其密度比进行评分：

$$h(\mathbf{z}_i, \mathbf{f}_j) = \exp\left(\frac{\mathbf{z}_i^\top \mathbf{f}_j}{\|\mathbf{z}_i\| \cdot \|\mathbf{f}_j\|} \cdot \frac{1}{\tau}\right). \quad (12)$$

我们根据经验对向量进行归一化，以测量单位空间中的比率，而不是将它们投影到公共空间中，这有助于保持内容信息的特征。

2.3.3 Contrastive Optimization.

为了最大化互信息，我们执行对比训练策略来优化模型的参数。结合定义的密度比函数，我们将目标函数实现为，

$$\begin{aligned} \mathcal{L} &= \lambda \mathcal{L}_{RE} + (1 - \lambda) \mathcal{L}_{UI} + \eta \|\Theta\|_2^2 \\ &= -\lambda \mathbb{E}_{i \in I} \left[\ln \frac{\exp\left(\frac{\mathbf{z}_i^\top \mathbf{f}_i}{\|\mathbf{z}_i\| \cdot \|\mathbf{f}_i\|} \cdot \frac{1}{\tau}\right)}{\exp\left(\frac{\mathbf{z}_i^\top \mathbf{f}_i}{\|\mathbf{z}_i\| \cdot \|\mathbf{f}_i\|} \cdot \frac{1}{\tau}\right) + \sum_{k=1}^K \exp\left(\frac{\mathbf{z}_i^\top \mathbf{f}_{j_k}}{\|\mathbf{z}_i\| \cdot \|\mathbf{f}_{j_k}\|} \cdot \frac{1}{\tau}\right)} \right] \\ &\quad - (1 - \lambda) \mathbb{E}_{(u, i) \in O} \left[\ln \frac{\exp\left(\frac{\mathbf{z}_i^\top \mathbf{z}_u}{\tau}\right)}{\exp\left(\frac{\mathbf{z}_i^\top \mathbf{z}_u}{\tau}\right) + \sum_{k=1}^K \exp\left(\frac{\mathbf{z}_{j_k}^\top \mathbf{z}_u}{\tau}\right)} \right] + \eta \|\Theta\|_2^2. \end{aligned} \quad (13)$$

Relation with BPR Loss.

在函数中，我们发现BPR损失可以被视为LUI的特例，设置时 τ 作为1，并采样一对负样本进行训练。然而，我们建议LUI 优于BPR损失。一方面，直觉上更接近现实世界，我们倾向于面对多种选择，而不是非此即彼的情况。另一方面，我们指出该函数本质上促进了模型优化。特别地，我们计算LUI 相对于 z_i 的梯度：

$$\frac{\partial \mathcal{L}_{UI}}{\partial z_i} = \left(\frac{\sum_{k=1}^K \exp(z_{jk}^\top z_u / \tau)}{\exp(z_i^\top z_u / \tau) + \sum_{k=1}^K \exp(z_{jk}^\top z_u / \tau)} \right) \left(-\frac{z_i}{\tau} \right) \frac{\partial z_u^\top}{\partial z_i}. \quad (14)$$

在训练过程中，负面内容越来越远离没有互动的用户。因此，负数对的得分接近于零，并且上述梯度的贡献主要来自硬负数项。对于BPR损失，它受到随机负采样的负面影响，随机负采样以低概率获得硬负。LUI 得益于其多个负样本，这明显增加了难负样本检测的概率，从而为优化提供了有意义的更大梯度[28]。

Hybrid Contrastive Training.

如第2.2节所述，最大化R-E互信息可以改善 z_i 和 f_i 之间的相关性，然后将 $\sum_{(u,i) \in O} \ln p(z_u | z_i, f_i)$ 近似为 $\sum_{(u,i) \in O} \ln p(z_u | z_i)$ 。然而，在训练阶段开始时，他们之间仍有差距。为了缓解这一缺陷，我们在U-I CEN中根据经验使用了混合训练策略，如图2所示。特别是，我们随机选择具有预定义概率 ρ 的学习特征表示或项目协同嵌入，并将其输入到密度比函数中。它能够最大化学习特征和用户偏好之间的相关性，并对训练阶段的协同嵌入进行建模。利用这种设计的优势，我们可以通过测量用户在推理阶段表示的相似性来预测用户和冷启动项目之间的亲和力。




Figure 2: Illustration of the hybrid contrastive training.

